


Завдання 4, варіант 7

Завантажуємо дані з файлу mix7.txt та рисуємо гістограму відносних частот:

```
data <- read.table(file="~/Downloads/regrasympt-1/mix7.txt",header=F)
```

```
X <- data$V1
```

```
hist(X, probability=TRUE)
```



На гістограмі помітно один суттєвий пік, тому можна було б сказати, що $M = 1$ або максимум $M = 2$. Але оскільки $M = 3$, то візьмемо як початкові наближення для математичних сподівань приблизні координати великого піку та малого, що знаходиться правіше від великого, дець в районі $x = 4$. Отже, ці три координати будуть такі: -1, 1, 4. Дисперсії оцінити важко, тому виберемо їх рівними 1. Початкові концентрації компонент візьмемо однаковими – 0.33.

```
M <- 3
```

```
p0 <- c(0.33, 0.33, 0.34)
```

```
a0 <- c(-1, 1, 4)
```

```
s0 <- c(1, 1, 1)
```

Запишемо код для ЕМ-алгоритму:

```
# Функція, що реалізує один крок ЕМ-алгоритму
# Аргументи:
# X – вибірка
# p0 - початкове наближення ймовірностей змішування
# a0 - початкове наближення математичних сподівань компонент
# s0 - початкове наближення дисперсій компонент
# Результат - фрейм даних зі стовпчиками:
# $p - наступне наближення ймовірностей змішування
# $a - наступне наближення математичних сподівань компонент
# $s - наступне наближення дисперсій компонент
```

```
EMstep <- function(X,p0,a0,s0){
  M <- length(p0)
  n <- length(X)
  w <- matrix(nrow=n,ncol=M)
  Wc <- numeric(M)
  for(j in 1:n){
    for(m in 1:M){
      w[j,m] <- p[m]*dnorm(X[j],a0[m],sqrt(s0[m])) }
    WS <- sum(w[j,])
    w[j,] <- w[j,]/WS }

  for(m in 1:M){
    Wc[m] <- sum(w[,m])
    a0[m] <- sum(w[,m]*X)/Wc[m]
    s0[m] <- sum(w[,m]*(X-a0[m])^2)/Wc[m] }

  p0 <- Wc/sum(Wc)

  return(data.frame(p=p0,a=a0,s=s0))
}
```

```
# Оцінка параметрів суміші з використанням ЕМ-алгоритму
# Аргументи:
# X – вибірка
# p0 - початкове наближення ймовірностей змішування
# a0 - початкове наближення математичних сподівань компонент
# s0 - початкове наближення дисперсій компонент
# delta - точність наближеного обчислення оцінки
```

```

# MaxIter - максимальна кількість кроків алгоритму
# Результат - фрейм даних зі стовпчиками:
# $p - оцінка ймовірностей змішування
# $a - оцінка математичних сподівань компонент
# $s - оцінка дисперсій компонент

EMalgorithm <- function(X,p,a,s,delta=0.0001,MaxIter=100){
  M <- length(p)
  z <- data.frame(p,a,s)
  B<-0
  repeat{
    z1 <- EMstep(X,z$p,z$a,z$s)
    B <- B+1
    if(sum(abs(z1-z))<delta) break
    z <- z1
    if(B > MaxIter) break  }
  return(z1)
}

```

Початкові наближення ми вже задали раніше, тому запускаємо алгоритм:

```
z<- EMalgorithm(X,p0,a0,s0)
```

```
z
```

	p	a	s
1	0.4100501	0.0308099864	6.9770055
2	0.1987996	-0.1060555367	0.2400185
3	0.3911502	0.0006392733	1.3252512

Оцінені значення параметрів бачимо у таблиці. Кожен рядок відповідає одній компоненті, кожен стовпчик - параметру. Якщо подивитись на математичні сподівання, видно, що вони зосереджені в районі центрального піку. Концентрації 1 та 3 компонент є майже рівними, а для 2 вона є вдвічі меншою за концентрації 1 і 3. Оцінюваних параметрів ми не знаємо, тому адекватність моделі перевіримо, порівнявши розподіл даних з тим, який пропонує підігнана модель. Для цього нарисуємо гістограму разом з щільністю розподілу суміші з оціненими параметрами:


```

# Функція для обчислення щільності розподілу суміші
# x - точка, в якій обчислюється щільність
# z - фрейм зі значеннями параметрів, що виводить EMalgorithm()

```

```
dens <- Vectorize(function(x,z){
  sum(sapply(1:M,function(i)z$p[i]*dnorm(x,z$a[i],sqrt(z$s[i]))))
},"x")

hist(X, probability=TRUE)
curve(dens(x,z),col="blue",add=TRUE)
```



З рисунку бачимо, що оцінена щільність гарно відображає розподіл даних.

Аналогічно проведемо підгонку розподілу даних з використанням 2-компонентної моделі. Дуже схоже, що наша модель має 2 компоненти.

M = 2:

```
M <- 2
```

```
p0 <- c(0.5, 0.5)
```


```
a0 <- c(-1, 1)
```

```
s0 <- c(1, 1)
```

```
> z
```

	p	a	s
1	0.6334717	-0.03365106	0.8715957
2	0.3665283	0.03578682	7.8474633

```
hist(X, probability=TRUE)  
curve(dens(x,z),col="blue",add=TRUE)
```



Дивлячись обидва графіки, для $M = 2$ та $M = 3$, краща підгонка вийшла для двокомпонентної моделі. Оцінена щільність гарно відображає розподіл даних, і, як на мене, більш точно ніж для $M = 3$.