


Оптимізаційні задачі в статистиці  
4 курс, статистика, Шкляр Ірина Володимирівна

Завдання 1, варіант 7

У роботі потрібно оцінити невідомий момент зміни розподілу за даними.

Завантажимо дані та нарисуємо діаграму точок:



```
> data <- read.table(file="~/Downloads/regrasympt/chp7.txt",header=T)
> x <- data$x
> plot(x)
```



З рисунка, на мою думку, точка зміни розподілу = приблизно 350. Тобто, маємо два інтервали однорідності: один – до можливого моменту зміни, інший – після 350 і до кінця.



Подивимось гістограми для першого і другого інтервалів (другий інтервал взяла з 530, щоб не включати два великих значення, які скоріш за все є викидами):

```
> hist(x[1:350])
> hist(x[530:950])
```



З гістограм видно, що розподіл є або експоненційним або логнормальним. Перевіримо його на логнормальність, прологарифмувавши дані:

```
> y <- log(x)
> hist(y[1:350])
> hist(y[530:950])
```



Бачимо, що отримані розподіли дуже схожі на нормальні. Тому я вибрала модель (с), для того, щоб легше було рахувати щільність – порахуємо нормальну щільність для прологарифмованих даних. Далі, рахуючи результати, перевіримо, чи буде змінюватись дисперсія при переході через точку зміни. Тоді ми точно побачимо, чи підходить нам модель (с) чи (b).

```

> Est <- function(ch, x){
+   n <- length(x)
+   m1 <- mean(x[1:ch])
+   m2 <- mean(x[(ch+1):n])
+   s1 <- var(x[1:ch])
+   s2 <- var(x[(ch+1):n])
+   return(c(m1, m2, s1, s2))
+ }
>
> LogLik <- function(ch, x){
+   z <- Est(ch, x)
+   -sum((x[1:ch]-z[1])^2)/(2*z[3])-sum((x[(ch+1):length(x)]-z[2])^2)/(2*z[4])-ch*log(z[3])/2-
+   (length(x)-ch)*log(z[4])/2
+ }

```

Отримали такі результати:

```

> LogLik(350, y)
[1] -986.3527
> Est(350, y)
[1] 0.9248509 0.9670014 1.1810808 4.0956710

```

Бачимо з оцінок, що дисперсії різні для двох інтервалів, отже модель вибрали правильну. 1.18 – дисперсія для першого інтервалу, 4.0956 – для другого.


Подивимось на графік логарифмічної функції вірогідності:

```

> LL <- sapply(2:(length(y)-2), LogLik, x=y)
> plot(LL, type="l")
>
> # момент зміни для послідовності x
> EstChP <- which.max(LL)
> EstChP
[1] 325
>
> abline(v=EstChP, col='red')

```

Оцінка моменту зміни розподілу вийшла 325. Отже, моє припущення виявилось правильним, що момент зміни розподілу знаходиться близько 350. Графік наведено нижче:




Далі, нарисуємо гістограми для наших оцінок з відповідними підігнаними теоретичними щільностями:

Для першого інтервалу:


```
> x1 <- x[1:325]
> hi <- hist(x1)
> curve(dnorm(x, mean=0.9248509, sd=1.1810808)*length(x)*(hi$breaks[2]-hi$breaks[1]),
col="darkblue", lwd=2, add=TRUE, yaxt="n")
```

Histogram of x1




Для другого інтервалу:

```
> x2 <- x[530:950]
> hi <- hist(x2)
> curve(dnorm(x, mean=0.9670014, sd=4.0956710)*length(x)*(hi$breaks[2]-hi$breaks[1]),
col="darkblue", lwd=2, add=TRUE, yaxt="n")
```



Спробуємо подивитись гістограми для прологарифмованих даних з підігнаними гауссовими щільностями. Також для кращої точності я почистила дані від викидів.

```
> plot(x)
```




Для очищених даних трішки змінились значення:

```
> LogLik(350, y)
[1] -954.0632
> Est(350, y)
[1] 0.9248509 0.9071573 1.1810808 3.8027796
```


EstChP внаслідок очищення від викидів не змінилося. Залишилося 325.

Далі подивимось на самі гістограми:

```
y1 <- y[1:325]
hi <- hist(y1)
curve(dnorm(x, mean=0.9248509, sd=1.1810808)*length(x)*(hi$breaks[2]-hi$breaks[1]),
col="darkblue", lwd=2, add=TRUE, yaxt="n")
```




```
> y2 <- y[326:950]
> hi <- hist(y2)
> curve(dnorm(x, mean=0.9071573, sd=3.8027796)*length(x)*(hi$breaks[2]-hi$breaks[1]),
col="darkblue", lwd=2, add=TRUE, yaxt="n")
```




Спробуємо використовувати гістограми відносних, а не абсолютних частот:

```
> y1 <- y[1:325]  
> hi <- hist(y1, probability=TRUE)  
> curve(dnorm(x, mean=0.9248509, sd=1.1810808), col="darkblue", lwd=2, add=TRUE,  
yaxt="n")
```





```
> y2 <- y[326:950]
> hi <- hist(y2, probability=TRUE)
> curve(dnorm(x, mean=0.9071573, sd=3.8027796), col="darkblue", lwd=2, add=TRUE,
yaxt="n")
```



Дійсно, порівнюючи гістограми відносних частот з щільностями, ми отримали набагато кращі рисунки.

Висновок: бачимо те, що параметри підібрані більш менш добре, по графікам щільностей з гістограмами. Оцінка моменту зміни розподілу вийшла 325, моє припущення було, що вона дорівнює приблизно 350, отже тут також помилок немає. Тому, я вважаю, що оцінювання є точним.