

Завдання 2, варіант 7

В роботі потрібно підібрати регресійну формулу та оцінити невідомі параметри a і b . Також вказати довірчі інтервали та провести аналіз залишків.


Завантажимо дані та подивимось діаграму розсіювання:

```
data <- read.table(file="~/Downloads/regrasymp/D7.txt",header=T)
```

```
x <- data$x
```


```
y <- data$y
```

```
plot(x, y, cex=0.5)
```



Бачимо, що графік дуже схожий або на $\cos/\ln$ або $\sin/\ln$. Якщо придивитися до лівої прямої, то точно видно, що це $\sin/\ln$.

Спочатку я пробувала на око та через сторонні програми побудови графіків підбирати параметри, що підходили б нашій діаграмі розсіювання. Далі я спробувала вручну через формули їх порахувати (знизу рисунок як я візуально шукала період та дані для обчислення a):



Для параметра b я дивилася приблизний період графіку. Параметр T я визначила на око з діаграми: десь 2.2 ($3.6 - 1.4 = 2.2$). Рахуємо b :

$$bT = 2\pi$$

$$b = 2 * 3.14 / 2.2 = 2.86$$

Тепер порахуємо a (використаємо тут наближення синуса до одиниці) :

$$\sin(bx) / \ln(x+a) = 1 / \ln(x+a)$$

Візьмемо точку $x=2.5$, $y=1$:

$$1 / \ln(a+2.5) = 1$$

$$a = 0.2183$$

Підставляємо наші приблизні значення:


```
fit <- nls(y ~ sin(b0*x)/log(a0+x), start = list(a0=0.2183, b0=2.86))
```

```
plot(x,y,cex=0.5)
```

```
a0<-coef(fit)["a0"]
```

```
b0<-coef(fit)["b0"]
```

```
curve(sin(b0*x)/log(a0+x),col="red",add=T)
```



Бачимо, що пряма підібрана ідеально до діаграми розсіювання. Подивимось оцінки та довірчі інтервали:

```
summary(fit)
```

Formula: $y \sim \sin(b_0 * x) / \log(a_0 + x)$

Parameters:

	Estimate	Std. Error	t value	Pr(> t)
a0	0.2001122	0.0003765	531.5	<2e-16 ***
b0	3.0010780	0.0035567	843.8	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.2066 on 498 degrees of freedom

Number of iterations to convergence: 4

Achieved convergence tolerance: 3.285e-06

Отримали оцінки $a=0.2001$, $b=3.001$.

```
confint(fit,level=0.95)
```

	2.5%	97.5%
a0	0.1993656	0.2008467
b0	2.9941333	3.0080356

Довірчі інтервали для рівня значущості $\alpha=0.05$:

для a – $[0.1993656, 0.2008467]$,

для b – $[2.9941333, 3.0080356]$.


Середньоквадратична похибка залишків дорівнює 0.2066.

Подивимось графічний аналіз залишків:

```
u<-residuals(fit)
```

```
pr<-fitted(fit)
```


```
plot(pr, u, xlab="Prediction", ylab="Residuals")
```



На діаграмі прогноз-залишки не бачимо закономірностей, що дозволяли б поліпшити прогноз.

Подивимось гістограму залишків:


```
hist(u)
```



Бачимо, що залишки (похибки) мають нормальний розподіл.

Подивимось діаграму відгук-прогноз:


```
plot(y,pr,cex=0.5,xlab="Response",ylab="Prediction")  
abline(0,1,col="red")
```



Діаграма розсіювання відгук-прогноз показує, що прогноз добре відтворює поведінку відгуку.

Подивимось діаграму квантиль до квантиля для похибок:

```
qqnorm(u,col="blue",cex=0.2,main="Residuals normal QQ-diagram")  
qqline(u,col="red")
```



З QQ-діаграми бачимо, що похибки дійсно мають нормальний розподіл, як ми бачили з гістограми.

Отже, отримали остаточну модель для x і y :

$$y = \sin(3.001 \cdot x) / \ln(0.2001 + x) + \text{eps},$$

де eps – гауссова похибка з математичним сподіванням -0.008519976 і дисперсією 0.0425222 .