

Завдання 3, варіант 7

В роботі потрібно провести підгонку моделі логістичної регресії, використовуючи дані про виноградник. На основі підігнаної моделі провести класифікацію зразків вина. Маємо виноградники 1 і 2, та змінні: OD, Proline, Alcohol і Malic_acid.

Імпортуємо дані, замінимо 1 на 0, 2 на 1 для змінної Site та вилучаємо третій виноградник. Використаємо функцію glm() з опцією family = binomial(), яка задає модель логістичної регресії з бінарним відгуком для того, щоб подивитися підгонку моделі логістичної регресії за даними з файлу для опису апостеріорної ймовірності, що вино вироблено на 1 або 2 винограднику за змінними OD, Proline, Alcohol і Malic_acid.

```
w2 <- read.csv2(file="~/Downloads/regrasympt/wine.csv",header=T)
```

```
w2<-w2[w2$Site!=3,]      # вилучаємо третій виноградник
w2$Site<-w2$Site-1      # 1->0, 2->1
attach(w2)              # приєднуємо дані
```

```
res<-glm(Site~OD + Proline + Alcogol + Malic_acid, family = binomial()) # підгонка моделі
```

```
> res
```

```
Call:  glm(formula = Site ~ OD + Proline + Alcogol + Malic_acid, family = binomial())
```

```
Coefficients:
```

(Intercept)	OD	Proline	Alcogol	Malic_acid
156.37529	-0.28960	-0.02676	-9.78410	-2.78925

```
Degrees of Freedom: 129 Total (i.e. Null); 125 Residual
```

```
Null Deviance: 179.1
```

```
Residual Deviance: 10.08      AIC: 20.08
```

```
> confint(res,level=0.95)
```

```
Waiting for profiling to be done...
```

	2.5 %	97.5 %
(Intercept)	51.22449913	485.347775896
OD	-6.83042283	6.569546923
Proline	-0.07791733	-0.009948987
Alcogol	-31.52667327	-2.431936747
Malic_acid	-8.89847210	-0.414814464

```
clasif<-as.numeric(fitted.values(res)>0.5)          # класифікація виноградників
table(clasif, Site)                                # будуємо таблицю помилок класифікації
```

```
      Site
clasif 0  1
      0 59  1
      1  0 70
```

```
> summary(res)
```

Call:

```
glm(formula = Site ~ OD + Proline + Alcogol + Malic_acid, family = binomial())
```

Deviance Residuals:

```
      Min       1Q   Median       3Q      Max
-1.10894 -0.00075  0.00001  0.00031  2.37189
```

Coefficients:

```
              Estimate Std. Error z value Pr(>|z|)
(Intercept) 156.37529   99.34618   1.574   0.1155
OD           -0.28960    2.87950  -0.101   0.9199
Proline      -0.02676    0.01553  -1.723   0.0849 .
Alcogol      -9.78410    6.67496  -1.466   0.1427
Malic_acid   -2.78925    1.91059  -1.460   0.1443
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

```
Null deviance: 179.11 on 129 degrees of freedom
Residual deviance: 10.08 on 125 degrees of freedom
AIC: 20.08
```

Number of Fisher Scoring iterations: 11

Отримали таку модель для ймовірності того, що вино вироблено на другому винограднику:

$$P\{\text{Site} = 2\} = \text{Logist}(156.37529 - 0.2896\text{OD} - 0.02676\text{Proline} - 9.7841\text{Alcogol} - 2.78925\text{Malic_acid})$$

За таблицею помилок класифікації бачимо, що якість класифікатора на основі цієї моделі є більш ніж задовільною – частоти помилок для першого виноградника 0/59 = 0, а для другого – 1/71 = 0.014.

Спробуємо вилучити деякі змінні: OD і Proline, і перевіримо як зміниться якість класифікації:

```
res<-glm(Site ~ Proline + Alcogol + Malic_acid, family = binomial())
```

```
> summary(res)
```

Call:

```
glm(formula = Site ~ Proline + Alcogol + Malic_acid, family = binomial())
```

Deviance Residuals:

Min	1Q	Median	3Q	Max
-1.12324	-0.00068	0.00001	0.00025	2.36467

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	158.26897	96.69249	1.637	0.1017
Proline	-0.02776	0.01253	-2.216	0.0267 *
Alcogol	-9.91625	6.48325	-1.530	0.1261
Malic_acid	-2.90348	1.58772	-1.829	0.0674 .

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 179.11 on 129 degrees of freedom
Residual deviance: 10.09 on 126 degrees of freedom
AIC: 18.09

Number of Fisher Scoring iterations: 11

```
> confint(res,level=0.95)
```

Waiting for profiling to be done...

	2.5 %	97.5 %
(Intercept)	55.4960761	478.59888058
Proline	-0.0683427	-0.01198158
Alcogol	-31.1649903	-2.96347322
Malic_acid	-7.9941709	-0.81109739

```
clasif<-as.numeric(fitted.values(res)>0.5)
```

```
> table(clasif,Site)
```

	Site
clasif	0 1
	0 59 1
	1 0 70

Незважаючи на зменшення кількості регресорів, частота помилок класифікації зовсім не змінилася. Тому цю модель можна буде взяти як остаточну, якщо не будуть кращі інші моделі, з меншою кількістю змінних у наборі:

$$P\{\text{Site} = 2\} = \text{Logist}(55.4960761 - 0.0683427\text{Proline} - 31.1649903\text{Alcogol} - 7.9941709\text{Malic_acid})$$

Приберемо обидві змінні – Proline і OD.

```
res<-glm(Site ~ Alcogol + Malic_acid, family = binomial())
```

```
> summary(res)
```

Call:

```
glm(formula = Site ~ Alcogol + Malic_acid, family = binomial())
```

Deviance Residuals:

Min	1Q	Median	3Q	Max
-1.72276	-0.22926	0.03588	0.20994	2.75570

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	65.3869	12.2988	5.317	1.06e-07	***
Alcogol	-4.9688	0.9322	-5.330	9.82e-08	***
Malic_acid	-0.1941	0.3359	-0.578	0.563	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 179.11 on 129 degrees of freedom
Residual deviance: 51.96 on 127 degrees of freedom
AIC: 57.96

Number of Fisher Scoring iterations: 7

```
> confint(res,level=0.95)
```

Waiting for profiling to be done...

	2.5 %	97.5 %
(Intercept)	45.2335108	94.6655896
Alcogol	-7.1881942	-3.4404079
Malic_acid	-0.9050024	0.4644767

```
clasif<-as.numeric(fitted.values(res)>0.5)
```

```
> table(clasif,Site)
      Site
clasif 0  1
      0 52  6
      1  7 65
```

Бачимо, що частота помилок збільшилась.

Спробуємо ще таку модель. В минулому випадку ми прибрали ці дві змінні з набору (OD і Proline), а тепер спробуємо саме з ними двома:

```
res<-glm(Site ~ Proline + OD, family = binomial())
```

```
> summary(res)
```

Call:

```
glm(formula = Site ~ Proline + OD, family = binomial())
```

Deviance Residuals:

Min	1Q	Median	3Q	Max
-2.06841	-0.10407	0.02798	0.12166	2.83665

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	20.944668	5.330357	3.929	8.52e-05 ***
Proline	-0.014943	0.003237	-4.616	3.91e-06 ***
OD	-2.923292	1.277462	-2.288	0.0221 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 179.109 on 129 degrees of freedom
Residual deviance: 32.591 on 127 degrees of freedom
AIC: 38.591

Number of Fisher Scoring iterations: 7

```
> confint(res,level=0.95)
Waiting for profiling to be done...
                2.5 %      97.5 %
(Intercept) 12.61913860 34.195596253
Proline      -0.02295112 -0.009840986
OD           -5.95316094 -0.839947147
```

```
clasif<-as.numeric(fitted.values(res)>0.5)
```

```
> table(clasif,Site)
      Site
clasif  0  1
      0 57  3
      1  2 68
```

Тут в нас частоти для першого виноградника $2/59 = 0.034$, а для другого виноградника – $3/71 = 0.04225$. Якість є більш ніж задовільною.

Отже, оберемо як остаточну модель ту, що має змінні Proline і OD:

$$P\{\text{Site} = 2\} = \text{Logist}(12.6191386 - 0.02295112\text{Proline} - 5.95316094\text{OD})$$