

Фінальний проект,

з курсу Планування вибірових обстежень для 4 курсу, Статистика
тема: "Пошук оптимального вибіркового дизайну"

Шкляр Ірина Володимирівна

За допомогою генератора випадкових чисел зроблено відбір 10 районів, що утворюють вибірку ПВО. В кожному із 10 вибраних районів зроблено відбір (ПВВБП) 20 домогосподарств. В файлі mainfinal.txt знаходяться дані з файлів для всіх районів. Файли закинула в PyCharm, та дала на вхід програмі:

```
import pandas as pd
from scipy.stats import norm
from math import sqrt

df = pd.read_csv('mainfinal.txt', delimiter=r'\s+')

df9 = pd.read_csv('f9.txt', delimiter=r'\s+')
df22 = pd.read_csv('f22.txt', delimiter=r'\s+')
df37 = pd.read_csv('f37.txt', delimiter=r'\s+')
df41 = pd.read_csv('f41.txt', delimiter=r'\s+')
df54 = pd.read_csv('f54.txt', delimiter=r'\s+')
df34 = pd.read_csv('f34.txt', delimiter=r'\s+')
df5 = pd.read_csv('f5.txt', delimiter=r'\s+')
df32 = pd.read_csv('f32.txt', delimiter=r'\s+')
df64 = pd.read_csv('f64.txt', delimiter=r'\s+')
df3 = pd.read_csv('f3.txt', delimiter=r'\s+')
```

N_i ми взяли з файлу, де знаходиться основна інформація про область
Стефенс – кількість будинків в кожному з вибраних районів:

```
N9 = 296
N22 = 254
N37 = 174
N41 = 152
N54 = 585
N34 = 135
N5 = 110
N32 = 141
N64 = 968
N3 = 135

N = 31989
NI = 75
nI = 10
n = 20
```

Далі подивимось середні значення (середня ціна, яку готові заплатити за послуги кабельного телебачення) для 20 дг з кожного з десяти районів:

```
y9 = df9['4'].mean()
print("y9 =", y9)

y22 = df22['4'].mean()
print("y22 =", y22)

...
```

```
y9 = 15.0
y22 = 9.25
y37 = 12.0
y41 = 7.25
y54 = 3.25
y34 = 8.0
y5 = 11.5
y32 = 10.75
y64 = 6.75
y3 = 11.5
```

Бачимо для 54 району деяку аномалію. Там середня ціна, яку згодні заплатити за послуги кабельного телебачення = 3.25 (тому що більша частина домогосподарств відповіла або 5 або 0). Також для районів 41, 64 та 34 середні ціни є дещо низькими. В 1ій лабораторній роботі середнє значення дорівнювало 8.925, а в 2ій – для першої страти (сільська місцевість) = 10.909, а для другої (місто) = 9.91869, для пропорційного розміщення.

Тому, наша оцінка середнього може бути значно менша, ніж в попередніх лабораторних роботах.

За допомогою формул порахуємо оцінку середньої ціни:

```
t9 = float(df9['4'].sum() * N9/n)
t22 = float(df22['4'].sum() * N22/n)
t37 = float(df37['4'].sum() * N37/n)
t41 = float(df41['4'].sum() * N41/n)
t54 = float(df54['4'].sum() * N54/n)
t34 = float(df34['4'].sum() * N34/n)
t5 = float(df5['4'].sum() * N5/n)
t32 = float(df32['4'].sum() * N32/n)
t64 = float(df64['4'].sum() * N64/n)
t3 = float(df3['4'].sum() * N3/n)
```

```
t = [t9, t22, t37, t41, t54, t34, t5, t32, t64, t3]

# 1(б)
y_pi = NI * sum(t) / (N*nI)
print("Оцінка середньої ціни =", y_pi)
```

Оцінка середньої ціни = 5.586607896464409

Як і передбачалося, вона вийшла доволі низька через аномалії в певних районах.

Порахуємо оцінку дисперсії для оцінки середнього із 16 та побудуємо 95% довірчий інтервал:

```
i = 0
S2_T = 0
for i in range(0, 9):
    suma = (t[i] - sum(t)/nI)**2
    S2_T += suma
    i += 1

S2_T = S2_T / (nI-1)

S9 = df9['4'].var()
S22 = df22['4'].var()
S37 = df37['4'].var()
S41 = df41['4'].var()
S54 = df54['4'].var()
S34 = df34['4'].var()
S5 = df5['4'].var()
S32 = df32['4'].var()
S64 = df64['4'].var()
S3 = df3['4'].var()

suma9 = ((1 - n/N9)*S9*N9**2) / n
suma22 = ((1 - n/N22)*S22*N22**2) / n
suma37 = ((1 - n/N37)*S37*N37**2) / n
suma41 = ((1 - n/N41)*S41*N41**2) / n
suma54 = ((1 - n/N54)*S54*N54**2) / n
suma34 = ((1 - n/N34)*S34*N34**2) / n
suma5 = ((1 - n/N5)*S5*N5**2) / n
suma32 = ((1 - n/N32)*S32*N32**2) / n
suma64 = ((1 - n/N64)*S64*N64**2) / n
suma3 = ((1 - n/N3)*S3*N3**2) / n

sumD0 = suma9+suma22+suma37+suma41+suma54+suma34+suma5+suma32+suma64+suma3

D_PVDVE = ( ((1-nI/NI)*S2_T*NI**2)/nI + sumD0*NI/nI ) / N**2
print(D_PVDVE)

z_alpha = norm.ppf(0.975) # 1.959963984540054
# y = df['4'].mean()
# print(y)
y = 9.525
```

```
lower_price = y - z_alpha * sqrt(D_PVDVE)
upper_price = y + z_alpha * sqrt(D_PVDVE)

print(f"95% довірчий інтервал для середньої ціни за кабельне ТБ:
({lower_price:.2f}, {upper_price:.2f})")
```

Оцінка дисперсії для оцінки середнього = 1.449698745488739

95% довірчий інтервал для середньої ціни за кабельне ТБ: (7.17, 11.88)

Довірчий інтервал виглядає більш менш добре, тому що середня ціна, порахована як середнє з файлу, в якому об'єднані всі дані з наших районів, дорівнює 9.525.

Порівнюючи з результатами з попередніх лабораторних робіт:

Лаба1:

D_price = 0.47123992242919727

95% довірчий інтервал для середньої ціни за кабельне ТБ: (8.00, 9.85)

Лаба2:

95% довірчий інтервал для середньої ціни за кабельне ТБ: (7.99, 9.86)

0.22672887979882164 # D – дисперсія оцінки для пропорційного розміщення

95% довірчий інтервал для середньої ціни за кабельне ТБ: (7.99, 9.86)

0.2272944008030067 #D – дисперсія оцінки для розміщення Неймана

95% довірчий інтервал для середньої ціни за кабельне ТБ: (7.76, 10.09)

0.3510395559486096 #D – дисперсія оцінки для оптимального розміщення

Оцінка дисперсії є найменшою для пропорційного розміщення з лаби 2, отже тут ефективнішим є пропорційний відбір. На жаль, найбільша дисперсія вийшла саме у нашому двостадійному відборі.

Вартість обстеження:

Якщо просумувати вартості обстеження для всіх районів, то отримаємо 3600 доларів.

Вартість проведення обстеження для лаби 1 (ПВВБП) = 5196 доларів.

Тобто бачимо, що вартість обстеження при двостадійному відборі є набагато меншою, ніж при випадковому відборі без повернення. Але і якість, в моєму випадку, виявилась значно гіршою.

Найефективніший відбір, на мою думку, є точно один з відборів з 20ї лабораторної роботи. Якщо підсумувати:

- Пропорційний відбір має найнижчу дисперсію оцінки середньої ціни (0.2267) серед розглянутих видів відбору, що свідчить про вищу точність оцінки серед інших
- Довірчий інтервал є доволі вузьким (7.99, 9.86), хоча для розміщення Неймана він вийшов таким самим через майже однакові оцінки дисперсій. Порівнюючи з інтервалом для двостадійного відбору, який є доволі широким, результати були значно кращі
- Пропорційний відбір є значно простішим до реалізації ніж, наприклад, відбір Неймана. Порівнюємо саме з ним, тому що їх результати є майже однаковими, вони виявились найефективнішими

Тому вважаю найбільш ефективним відбором пропорційний відбір.

Нотатки (формули, номери районів, ціни за обстеження, і тд)

10 районів (випадково) по 20 домогосподарств

$n = 20$ $N_I = 75, n_I = 10, n_i = 20$

1:	9	380 \$
2:	22	380 \$
3:	37	380 \$
4:	41	380 \$
5:	54	280 \$
6:	34	380 \$
7:	5	380 \$
8:	32	380 \$
9:	64	280 \$
10:	3	380 \$

$N_1 = 296$ $N_2 = 4711 - 4457 = \dots$

$$\hat{S}_T^2 = \frac{1}{n_I - 1} \sum_{i \in S_I} \left(\hat{t}_{in} - \frac{1}{n_I} \sum_{i \in S_I} \hat{t}_{in} \right)^2$$

$$\hat{D}_{ПВББЕ}(\hat{t}_{in}) = N_I^2 \frac{1 - \frac{n_I}{N_I}}{n_I} \hat{S}_T^2 + \frac{N_I}{n_I} \sum_{i \in S_I} N_i^2 \frac{1 - \frac{n_i}{N_i}}{n_i} \hat{S}_i^2$$

$$\hat{D}_{ПВББЕ}(\hat{y}_{in})^2 = \frac{1}{N_I^2} \hat{D}_{ПВББЕ}(\hat{t}_{in})$$

Handwritten formula for $\hat{t}_{in}$ is also present: $\hat{t}_{in} = \frac{N_I}{n_I} \sum_{i \in S_I} \frac{N_i}{n_i} \sum_{k \in S_i} y_k$

2. Реалізація альтернативного відбору.

Я вирішила спробувати зробити такий поділ на страти: відділити два великих міста окремо (Локхард і Івествіль), а маленькі міста та сільську місцевість об'єднати в одну страту та застосувати пропорційне розміщення, виходячи з того, що я його вважаю найкращим з попередніх висновків. Отримуємо такі страти: населення міста Локхард (райони 51—75), населення міста Івествіль (райони 47—50), та населення переважно сільської місцевості (райони 1—46).

маленькі міста + сіль. місцевість

51-75 47-50 1-46 →

Локхард Івествіль

① 1-46: $N_1 = 9089$

$N = 31989$
 $n = 200$

② 47-50: $12325 - 9089 = 3236$ $N_2 = 3236$

③ 51-75: $31989 - 12325 = 19664$ $N_3 = 19664$

①: $n_1 = \frac{200 \cdot 9089}{31989} = 56,8 \approx 57$

②: $n_2 = \frac{200 \cdot 3236}{31989} = 20,2 \approx 20$ $= 200$

③: $n_3 = \frac{200 \cdot 19664}{31989} = 122,9 \approx 123$ $n = 1, 2, 3$

Генеруємо вибірку двох районів 1-46 розміром 57, 47-50 розміром 20; 51-75 розміром 123.

1: 2652 \$, 2: 340 \$, 3: 2099 \$.

Вартість обстеження = $2652 + 340 + 2099 = 5091$ дол. Ціна вийшла навіть чуть меншою, ніж для обстеження з 1ої лабораторної роботи (5196 дол.). Розмір вибірки буде 200. Отже всі обмеження на це завдання працюють.

```

import pandas as pd
from scipy.stats import norm
from math import sqrt

N = 31989
z_alpha = norm.ppf(0.975)

# strata 1
df1 = pd.read_csv('mf1.txt', delimiter=r'\s+')
N1 = 9089
n1 = 57

cable_var1 = df1['4'].var()
y1 = df1['4'].mean()
print("y1 =", y1)

# strata 2
df2 = pd.read_csv('mf2.txt', delimiter=r'\s+')
N2 = 3236
n2 = 20

cable_var2 = df2['4'].var()
y2 = df2['4'].mean()
print("y2 =", y2)

# strata 3
df3 = pd.read_csv('mf3.txt', delimiter=r'\s+')
N3 = 19664
n3 = 123

cable_var3 = df3['4'].var()
y3 = df3['4'].mean()
print("y3 =", y3)

D = ( (1 - n1/N1)*cable_var1*N1**2 )/(n1*N**2) + ( (1 -
n2/N2)*cable_var2*N2**2 )/(n2*N**2) + ( (1 -
n3/N3)*cable_var3*N3**2 )/(n3*N**2)
print(D)

y = 9.525
lower_price = y - z_alpha * sqrt(D)
upper_price = y + z_alpha * sqrt(D)
print(f"95% довірчий інтервал для середньої ціни за кабельне ТБ:
({lower_price:.2f}, {upper_price:.2f})")

```

у я взяла з першого завдання цієї лабораторної роботи. Також файли mf1, mf2, mf3 відповідають згенерованим вибіркам для районів.

Маємо такі результати:

$$y_1 = 11.052631578947368$$

$$y_2 = 8.25$$

$$y_3 = 9.91869918699187$$

$$0.23001723604540697$$

95% довірчий інтервал для середньої ціни за кабельне ТБ: (8.58, 10.47)

Бачимо дуже непогані результати, дисперсія є трішки вищою за наш найкращий результат: $0.23001723604540697 > 0.22672887979882164$ # D – дисперсія оцінки для пропорційного розміщення з лаби 2.

Інтервал є не дуже широким, та середні значення для трьох вибірок є більш менш адекватними.

Але я спробую ще одну ідею, можливо там ми зможемо отримати найнижчу дисперсію.

Розділимо домогосподарства на такі страти: перша (райони 1-46, маленькі міста та сільська місцевість), та друга (райони 47-75, міста Івествіль та Локхард разом). Тобто ця стратифікація трішки схожа на ту, що була в 2ій лабораторній роботі, але я її модифікувала під свій минулий метод, там де було три страти.

Handwritten calculations on grid paper:

Stratum	Population Size (N_i)	Sample Size (n_i)	Cost (\$)
1-46: маленькі міста та сільська місцевість	9089	57	2652
47-75: міста	22900	143	2439

Calculations shown:

- ①: 1-46: $N_1 = 9089 \Rightarrow n_1 = \frac{200 \cdot 9089}{31989} = 57$ 2652\$
- ②: 47-75: $N_2 = 22900 \Rightarrow n_2 = \frac{200 \cdot 22900}{31989} = 143$ 2439\$

Вартість обстеження = $2652 + 2439 = 5091$ дол. Точно така сама як для минулого обстеження. Розмір вибірки = 200. Знову всі обмеження на відбір виконано.


```

import pandas as pd
from scipy.stats import norm
from math import sqrt

N = 31989
z_alpha = norm.ppf(0.975)

# strata 1
df1 = pd.read_csv('new1.txt', delimiter=r'\s+')
N1 = 9089
n1 = 57

cable_var1 = df1['4'].var()
y1 = df1['4'].mean()
print("y1 =", y1)

# strata 2
df2 = pd.read_csv('new2.txt', delimiter=r'\s+')
N2 = 22900
n2 = 143

cable_var2 = df2['4'].var()
y2 = df2['4'].mean()
print("y2 =", y2)

D = ( (1 - n1/N1)*cable_var1*N1**2 ) / (n1*N**2) + ( (1 -
n2/N2)*cable_var2*N2**2 ) / (n2*N**2)
print(D)

y = 10.648
lower_price = y - z_alpha * sqrt(D)
upper_price = y + z_alpha * sqrt(D)
print(f"95% довірчий інтервал для середньої ціни за кабельне ТБ:
({lower_price:.2f}, {upper_price:.2f})")

```

Результати:

y1 = 11.052631578947368

y2 = 10.244755244755245

0.21969333650007586

95% довірчий інтервал для середньої ціни за кабельне ТБ: (9.73, 11.57)

Отримали доволі високі середні значення, які готові платити споживачі за кабельне ТБ, як для сільської місцевості, так і для міст. Вийшов неширокий довірчий інтервал. І найголовніше, найнижча дисперсія з усіх (лаби 1, 2,

перше завдання цієї лаби), 0.21969333650007586. Такий чудовий результат також пов'язаний з добре згенерованими вибірками.

Висновок:

Спробувавши дві ідеї як розділити вибірки на страти, найуспішнішою виявилась та, що має дві страти: сільська місцевість і два великих міста в одній страті. Варіант трьох страт виявився менш якісним, хоча теж з дуже хорошими результатами. Вартості обстежень обома методами виявились однаковими. Отже, розділення двох великих міст на дві окремі страти є таким самим по вартості, що і не розділяти їх на страти, але нераціональним.

Загалом, стратифікований відбір є і вигіднішим для нас ніж ПВВБП, і якіснішим, наприклад якщо порівнювати з двостадійним відбором, який вийшов в мене найменшим по вартості, та ПВВБП. Найпростішим розміщенням для реалізації стратифікованого відбору є пропорційний відбір, крім того він дав нам дуже якісні результати. Якщо казати про двостадійний відбір, взявши іншу вибірку для двостадійного відбору, результати могли б бути кращими.