

Лабораторна робота 1,
по «Плануванню вибірових обстежень» для 4 курсу, спец. «Статистика»
тема: "Простий випадковий відбір без повернення"

Шкляр Ірина Володимирівна

Для лабораторної роботи я використовувала два файли: addr.txt (для 20 обстежень) і addr200.txt (200 обстежень), згенерованих за допомогою навчальних програм addgen.exe і survey.exe. Припустимо, що опитані відповідали не випадковим чином.

1. Провести пробне обстеження 20 домогосподарств в області Стефенс за допомогою простого випадкового відбору без повернення. Оцінити:

(а) загальну кількість телевізорів в області Стефенс:

```
import pandas as pd

df = pd.read_csv('addr.txt', delimiter=r'\s+')

N = 31989
n = 20

# 1(a)
total_tvs = df['3'].sum() # 44
t = N * total_tvs / n # 70375.8
print(total_tvs)
print(t)
```

Порахували, що $t(20) = 70376$.

(б) середню ціну, яку погоджуються платити за послуги кабельного телебачення:

```
# 1(б)
y = df['4'].mean() # 9.75
print(y)
```

Середня ціна $y(20)$ вийшла 9.75 дол.

(в) дисперсії генеральної сукупності (S^2) по характеристиці y – «кількість телевізорів», та по характеристиці z – «ціна за послуги кабельного ТБ»:

```
# 1(в)
# y – «кількість телевізорів»
tv_variance = df['3'].var() # 0.7999999999999999
print(tv_variance)

# z – «ціна за послуги кабельного ТБ»
cable_variance = df['4'].var() # 24.93421052631579
print(cable_variance)
```

$S2_1$ вийшло 0.8, $S2_2$ вийшло 24.93421.

2. Підрахувати необхідний розмір вибірки, використовуючи інформацію з пробного обстеження, для проведення повноцінного обстеження, якщо потрібно оцінити одночасно та з 95% вірогідністю:

а) загальну кількість телевізорів в області Стефенс з абсолютною точністю = 2000:

```
import pandas as pd
from scipy.stats import norm

df = pd.read_csv('addr200.txt', delimiter=r'\s+')

# з минулого пункту
tv_var1 = 0.80
cable_var1 = 24.93
y = 9.75

# 2(a)
N = 31989
z_alpha = norm.ppf(0.975) # 1.959963984540054

d = 2000 # абсолютна точність
n_tvs = (N**2 * tv_var1) / ((d ** 2) / (z_alpha**2) + N*tv_var1)
print(int(n_tvs)) # 767
```

Необхідний розмір вибірки n1 вийшов 767.

б) середню ціну, яку погоджуються платити за послуги кабельного телебачення з відносною точністю е з хвилькою = 2%:

```
# 2(б)
e = 0.02 # Відносна точність
n_price = (cable_var1 * z_alpha**2) / ((y**2) * (e ** 2) + (z_alpha ** 2) *
cable_var1 / N)
print(int(n_price)) # 2334
```

Необхідний розмір вибірки n2 вийшов 2334.

Беремо з них максимум, щоб отримати n: виходить n=2334.

Чи достатньо буде для отримання бажаних точностей вибірки розміру 200?

```
if n_tvs and n_price <= 200:
    print("Достатньо")
else:
    print("Недостатньо")
```

Оскільки необхідні розміри дорівнюють 767 і 2334, то очевидно, що вибірки розміру 200 буде недостатньо, що ми і отримали при запуску цього шматочка коду.

3. Провести обстеження 200 домогосподарств та побудувати 95% довірчі інтервали для:

а) загальної кількості телевізорів в області Стефенс:

```
from math import sqrt

# 3(a)
N = 31989
n = 200

total_tvs = df['3'].sum()
t = N * total_tvs / n
print(int(t))    # 55021 = t(200)

tv_var = df['3'].var()
print(tv_var)    # 1.1171859296482411

D_tvs = sqrt((N**2 * (1 - n/N) * tv_var) / n)
lowerDI_tvs = t - z_alpha * D_tvs
upperDI_tvs = t + z_alpha * D_tvs
print(f"({int(lowerDI_tvs)}, {int(upperDI_tvs)})")
# (50349, 59692)
```

t(200) вийшло 55021.

95% довірчий інтервал для загальної кількості телевізорів дорівнює (50349, 59692).

б) середньої ціни, яку погоджуються платити за послуги кабельного телебачення:

```
# 3(б)
cable_var = df['4'].var()

y = df['4'].mean()
print(y)    # 8.925 = y(200)

D_price = sqrt(((1 - n/N) * cable_var) / n)
lower_price = y - z_alpha * D_price
upper_price = y + z_alpha * D_price
print(f"({lower_price:.2f}, {upper_price:.2f})")
# (8.00, 9.85)
```

y(200) вийшло 8.925.

95% довірчий інтервал для середньої ціни за кабельне ТБ дорівнює (8.00, 9.85).

в) пропорції домогосподарств, які погоджуються платити за кабельне ТБ хоча б 10 \$:

```
# 3(в)
print((df['4'] >= 10).sum())    #117
pay = (df['4'] >= 10).sum() / n
print(pay)    # 0.585 = p(200)
D_prop = sqrt(pay * (1 - pay) / n)
lower_prop = pay - z_alpha * D_prop
```

```
upper_prop = pay + z_alpha * D_prop
print(f"({lower_prop:.2f}, {upper_prop:.2f})")
# (0.52, 0.65)
```

p(200) вийшло 0.585, 117 з 200 домогосподарств погодились платити хоча б 10 дол. 95% довірчий інтервал для пропорції домогосподарств, які погодились платити хоча б 10 дол.: (0.52, 0.65).

Якого типу передачі найбільш популярні в області Стефенс?

```
news_hours = df['6'].sum()
print(news_hours)      # 844
sports_hours = df['7'].sum()
print(sports_hours)    # 2617
kids_hours = df['8'].sum()
print(kids_hours)      # 699
movies_hours = df['9'].sum()
print(movies_hours)    # 2438

max_hours = max(news_hours, sports_hours, kids_hours, movies_hours)
print(max_hours)       # 2617
```

Бачимо, що max_hours співпадають з sports_hours, тому спортивні передачі є найпопулярнішими.

4. По даним з вибірки побудувати 95% довірчий інтервал для середньої вартості будинків в області Стефенс:

```
# 4
suma = df['VALUE'].sum()
print(suma)      # 13412240

V = suma / n
V_var = df['VALUE'].var()

D_V = sqrt(((1 - n/N) * V_var) / n)
lower_V = V - z_alpha * D_V
upper_V = V + z_alpha * D_V
print(f"({lower_V:.2f}, {upper_V:.2f})")
# (64864.13, 69258.27)
```

95% довірчий інтервал для середньої вартості будинків дорівнює (64864.13, 69258.27).

Чи містить отриманий інтервал реальне значення 68 045 \$?

Бачимо, що так, містить.

На вашу думку, чи отримана вибірка є репрезентативною? Чому?

Оскільки, в нашому випадку, щоб отримати точні показники, потрібно опитати 2334 домогосподарства, то дані, які ми отримали є далеко не точними. І можливо таке, що для інших 200 учасників, найпопулярнішими будуть інші передачі, або вони зможуть платити іншу ціну за послуги ТБ.

5. Якби ви були на місці керівників компанії "SCCC", яке б рішення щодо виходу на ринок області Стефенс ви зробили? Поясніть чому?

Основаючись на дані з вибірки розміру 200, можна приблизно сказати, що в області Стефенс більше половини погодились платити 10 дол. і вище за послуги ТБ, тобто в середньому ця ціна або нижча (той інтервал, що ми знайшли для середньої ціни = (8.00, 9.85)) буде ідеальною для домогосподарств.

Також можна з впевненістю сказати, що 200 з 31989 домогосподарств не зовсім достатньо для отримання точних показників, найкраще буде опитати хоча б 2334 домогосподарства.

Можна додати, що для моїх 200 учасників опитування, найпопулярнішим типом телепередач були спортивні. Тобто, можна зробити більше спортивних телеканалів. На другому місці, з невеликим відривом, по переглядам є художні фільми, тому можна і на цьому зосередити увагу.