

Лабораторна робота 2,
з курсу Планування вибірових обстежень для 4 курсу, Статистика
тема: "Стратифікований відбір"

Шкляр Ірина Володимирівна

Населення області Стефенс можна поділити на страти таким чином: міське населення міста Стефенс (райони 51—75), та все інше (переважно сільське) населення (райони 1—50).

Отже, маємо дві страти: перша – сільське населення (1-50), друга – місто (51-75).

1. Результати з 1 лаби (ПВВБП).

cablе_var = 44.6928391959799

D_price = 0.47123992242919727

1.

$$\text{cable_var} = \hat{S}^2 = 44,69284. \quad n = 200.$$

$$D_price = \hat{D}_{\text{ПВВБП}}(\hat{y}_{\text{ст}}) = 0,47124.$$

$y(200) = 8.925$ – середня ціна (оцінка), яку готові платити за кабельне телебачення для $n = 200$.

2. Пропорційне розміщення.

2.
 З огляду інформації про кількісний склад районів (опис області Стефенс у файлі "PVO22-Stefanesc-opus.pdf") знах, що для районів 1-50 маємо 12325 буд. з 31989, а для районів 51-75: 31989 - 12325 = 19664. Отже, маємо дві страти.
 $N_1 = 12325, N_2 = 19664.$
 $N = 31989, n = 200 \Rightarrow \text{пропорційне розміщення}.$

$$h_h = \frac{n N_h}{N} \quad n_1 = \frac{200 \cdot N_1}{31989} = \frac{200 \cdot 12325}{31989} = 77.$$

$$h_2 = \frac{200 \cdot 19664}{31989} = 123. \quad n_1 + n_2 = 77 + 123 = 200.$$

 Отже, маємо згенерувати вибірку для районів 1-50 розміром 77, і 51-75 розміром 123.

$$\hat{D}_{\text{стПВВБП}}(\hat{y}_{\text{ст}}) = \frac{1}{N^2} \sum_{h=1}^H N_h^2 \left(1 - \frac{n_h}{N_h}\right) \frac{\hat{S}_h^2}{n_h} = \frac{1}{N^2} \left(\right)$$

Стратифікована вибірка із пропорційним розміщенням:

За допомогою навчальних програм addgen.exe і survey.exe було згенеровано вибірку розміром 77 для першої страти (райони 1-50) – s2_1.txt і вибірку розміром 123 для другої страти (райони 51-75) – s2_2.txt.

$$\left(N_1^2 \left(1 - \frac{n_1}{N_1} \right) \frac{\hat{S}_1^2}{n_1} + N_2^2 \left(1 - \frac{n_2}{N_2} \right) \frac{\hat{S}_2^2}{n_2} \right) \cdot \frac{1}{31989^2}$$

$$= \left(12325^2 \left(1 - \frac{77}{12325} \right) \cdot \frac{\hat{S}_1^2}{77} + 19664^2 \left(1 - \frac{123}{19664} \right) \frac{\hat{S}_2^2}{123} \right) \cdot \frac{1}{31989^2}$$

$$= \frac{1}{31989^2} \left(1960475,324675 \cdot \hat{S}_1^2 + 3124018,0813 \cdot \hat{S}_2^2 \right)$$

$$= 0,0019158 \hat{S}_1^2 + 0,003053 \hat{S}_2^2 \quad \text{③}$$

$\hat{S}_1^2$ і $\hat{S}_2^2$ *попущено в код*. $\hat{S}_1^2 = 44,5574168$
 $\hat{S}_2^2 = 46,3048114$
cable_var1
 ~~$0,0853631 + 0,14137 = 0,2267317$~~
 ~~$0,0853631 + 0,14137 = 0,2267317$~~

Нижче наведений код для підрахунку формул:

```
import pandas as pd
from scipy.stats import norm
from math import sqrt

N = 31989
z_alpha = norm.ppf(0.975)

# strata 1
df1 = pd.read_csv('s2_1.txt', delimiter=r'\s+')
N1 = 12325
n1 = 77

cable_var1 = df1['4'].var()
print("cable_var1 =", cable_var1)

y1 = df1['4'].mean()
print("y1 =", y1)

# strata 2
df2 = pd.read_csv('s2_2.txt', delimiter=r'\s+')
N2 = 19664
n2 = 123

cable_var2 = df2['4'].var()
print("cable_var2 =", cable_var2)
```

```

y2 = df2['4'].mean()
print("y2 =", y2)

D = ( (1 - n1/N1)*cable_var1*N1**2 ) / (n1*N**2) + ( (1 -
n2/N2)*cable_var2*N2**2 ) / (n2*N**2)
print(D)

```

Маємо такі результати (частково деякі з них вже були вписані на листочку):

```

cable_var1 = 44.557416267942585
y1 = 10.909090909090908
cable_var2 = 46.30481140876982
y2 = 9.91869918699187
0.22672887979882164 # D – дисперсія оцінки

```

Середня ціна, яку готові платити за кабельне телебачення для першої страти (сільська місцевість: райони 1-50) = 10.909090909090908.

Середня ціна, яку готові платити за кабельне телебачення для другої страти (місто: райони 51-75) = 9.91869918699187.

Ціни вийшли вищі, ніж для вибірки $n = 200$ з лаби 1. Там середня ціна була 8.925.

Вартість обстеження вийшла така:

$C1 = 3058$ – вартість для першої страти, $C2 = 2099$ – вартість для другої страти.

Отже, $C = 3058 + 2099 = 5157$ доларів.

Вартість проведення обстеження для лаби 1 (ПВВБП) = 5196 доларів.

Отже, дійсно, за допомогою стратифікованого відбору можна заощадити на обстеженні. Ціна не дуже суттєво відрізняється, але все одно є трішки меншою.

3. Розміщення Неймана.

```

S1 = sqrt(cable_var1)
S2 = sqrt(cable_var2)

n = 200

nn1 = n*N1*S1 / (N1*S1 + N2*S2)
print("neyman n1 =", nn1)
nn1 = 76

nn2 = n*N2*S2 / (N1*S1 + N2*S2)
print("neyman n2 =", nn2)
nn2 = 124

```

З формул для $nn1$ і $nn2$ знаходимо, що:

neyman $n1 = 76.14870850613924$

neyman $n2 = 123.85129149386076$

Тому, приблизно беремо значення $nn1 = 76$ і $nn2 = 124$. В сумі дорівнюють 200.

3. розподіл Неймана: $n=200$ $\hat{S}_1 = \sqrt{S_1^2}$ $\hat{S}_2 = \sqrt{S_2^2}$

$$n_h = n \cdot \frac{N_h S_h^2}{\sum_{h=1}^H N_h S_h^2}$$

$$n_1 = n \cdot \frac{N_1 \hat{S}_1^2}{N_1 \hat{S}_1^2 + N_2 \hat{S}_2^2}$$

$$n_2 = n \cdot \frac{N_2 \hat{S}_2^2}{N_1 \hat{S}_1^2 + N_2 \hat{S}_2^2}$$

$\hat{S}_1 = 6,675134$
 $\hat{S}_2 = 6,804764$

Отже, потрібно згенерувати: $n_1 = 76$ $n_2 = 124$

де 1-50 - вид. з 76 ел., 51-75 - вид. з 124 ел.

Стратифікована вибірка із розміщенням Неймана:

Було згенеровано вибірку розміром 76 для першої страти (райони 1-50) – i2_1.txt
і вибірку розміром 124 для другої страти (райони 51-75) – i2_2.txt.

$$\hat{D}_{\text{Нейман}}(\hat{y}_n) = \frac{1}{N^2} \left(N_1^2 \left(1 - \frac{n_1}{N_1} \right) \frac{\hat{S}_1^2}{n_1} + N_2^2 \left(1 - \frac{n_2}{N_2} \right) \frac{\hat{S}_2^2}{n_2} \right)$$

$$= \frac{1}{39989^2} \left(12325^2 \left(1 - \frac{76}{12325} \right) \frac{\hat{S}_1^2}{76} + 19664^2 \left(1 - \frac{124}{19664} \right) \frac{\hat{S}_2^2}{19664} \right)$$

$$= 0,2272944$$

```
# strata 1
dfn1 = pd.read_csv('i2_1.txt', delimiter=r'\s+')

cable_varn1 = dfn1['4'].var()
print("neyman cable_var1 =", cable_varn1)

yn1 = dfn1['4'].mean()
print("neyman y1 =", yn1)

# strata 2
dfn2 = pd.read_csv('i2_2.txt', delimiter=r'\s+')

cable_varn2 = dfn2['4'].var()
print("neyman cable_var2 =", cable_varn2)

yn2 = dfn2['4'].mean()
print("neyman y2 =", yn2)

D_neyman = ( (1 - nn1/N1)*cable_varn1*N1**2 )/(nn1*N**2) + ( (1 -
nn2/N2)*cable_varn2*N2**2 )/(nn2*N**2)
print(D_neyman)
```

Маємо такі результати:

neuman cable_var1 = 45.14035087719298
 neuman y1 = 10.921052631578947
 neuman cable_var2 = 46.12345921846315
 neuman y2 = 9.879032258064516
 0.2272944008030067 # D – дисперсія оцінки

Середня ціна, яку готові платити за кабельне телебачення для першої страти (сільська місцевість: райони 1-50) = 10.921052631578947. Трішки більша ніж для пропорційного розміщення.

Середня ціна, яку готові платити за кабельне телебачення для другої страти (місто: райони 51-75) = 9.879032258064516. А тут ціна трішки менша ніж для пропорційного розміщення.

Також ціни вийшли вищі, ніж для вибірки $n = 200$ з лаби 1 (ПВВБП). Там середня ціна була 8.925.

Дисперсія оцінки для розміщення Неймана є трішки вищою ніж для пропорційного розміщення ($0.2272944008030067 > 0.22672887979882164$), але обидві нижчі ніж для ПВВБП (0.47123992242919727).

4. Оптимальне розміщення.

ч. $C_1 = 3058, C_2 = 2099$
 $C = C_1 + C_2 = 5157$ \$
 $C_0 = 0$
 $c_1 = 75$ \$ місто, $c_2 = 15$ \$ с.с. місцевість
 $n_h = \lambda \frac{N_h \hat{S}_h}{\sqrt{C_h}}$
 $n_1 = \lambda \cdot \frac{N_1 \hat{S}_1}{\sqrt{15}} = 74$
 $n_2 = \lambda \cdot \frac{N_2 \hat{S}_2}{\sqrt{75}} = 54$ 3 кося
 $\lambda = \frac{C - C_0}{\sum_{h=1}^H \sqrt{C_h} \cdot N_h \hat{S}_h}$
 $\lambda = \frac{5157 - 0}{12325 \cdot \hat{S}_1 \sqrt{15} + 19664 \cdot \hat{S}_2 \sqrt{75}}$
 $74 \cdot 15 + 54 \cdot 75 = 1110 + 4050 = 5160 \approx 5157$. Отже,
 n_1 і n_2 прийнято правильно. Генеруємо такі
 вибірки: для 1-50 74 елементи, для 51-75
 54 елементи.
 $\hat{D}_{\text{СТІТБВ}}^{\text{opt}}(\hat{y}_{\text{opt}}) = \frac{1}{N^2} \left(N_1^2 \left(1 - \frac{n_1}{N_1} \right) \frac{\hat{S}_1^2}{n_1} + N_2^2 \left(1 - \frac{n_2}{N_2} \right) \frac{\hat{S}_2^2}{n_2} \right) = \text{кося} = 0,35104$

```

c0 = 0
c1 = 15
c2 = 75
C = 5157

lambda1 = (C-c0)/(N1*S1*sqrt(c1) + N2*S2*sqrt(c2))

no1 = lambda1*N1*S1/sqrt(c1)
no2 = lambda1*N2*S2/sqrt(c2)

print('optimal n1 =', no1)
print('optimal n2 =', no2)

no1 = 74
no2 = 54

```

З формул для no1 і no2 знаходимо, що:

optimal n1 = 74.14548315491663

optimal n2 = 53.93090336901667

Тому, приблизно беремо значення no1 = 74 і no2 = 54.

Перевірки чи правильно знайдені n1 і n2 наведена на листочку вище.

Стратифікована вибірка із оптимальним розміщенням:

Було згенеровано вибірку розміром 74 для першої страти (райони 1-50) – o2_1.txt

і вибірку розміром 54 для другої страти (райони 51-75) – o2_2.txt.

Наш код для обчислень:

```

# strata 1
dfo1 = pd.read_csv('o2_1.txt', delimiter=r'\s+')

cable_varo1 = dfo1['4'].var()
print("optimal cable_var1 =", cable_varo1)

yo1 = dfo1['4'].mean()
print("optimal y1 =", yo1)

# strata 2
dfo2 = pd.read_csv('o2_2.txt', delimiter=r'\s+')

cable_varo2 = dfo2['4'].var()
print("optimal cable_var2 =", cable_varo2)

yo2 = dfo2['4'].mean()
print("optimal y2 =", yo2)

D_opt = ( (1 - no1/N1)*cable_varo1*N1**2 )/(no1*N**2) + ( (1 -
no2/N2)*cable_varo2*N2**2 )/(no2*N**2)
print(D_opt)

```

Маємо такі результати:

optimal cable_var1 = 43.3728248796742

optimal y1 = 10.675675675675675

optimal cable_var2 = 37.91055206149546
optimal y2 = 8.703703703703704
0.3510395559486096 # D – дисперсія оцінки

Середня ціна, яку готові платити за кабельне телебачення для першої страти (сільська місцевість: райони 1-50) = 10.675675675675675. Вийшла менша ніж для пропорційного розміщення і розміщення Неймана.

Середня ціна, яку готові платити за кабельне телебачення для другої страти (місто: райони 51-75) = 8.703703703703704. Також ціна менша ніж для пропорційного розміщення і розміщення Неймана.

Ціна для першої страти вийшла вища, ніж для вибірки $n = 200$ з лаби 1 (ПВВБП). Але для другої страти (вперше серед інших розміщень) вийшла менша за середню ціну для ПВВБП (8.925).

Дисперсія оцінки для оптимального розміщення є вищою за дисперсії для пропорційного розміщення та розміщення Неймана
(0.3510395559486096 > 0.2272944008030067,
0.3510395559486096 > 0.22672887979882164) ,
але усе одно є нижчою ніж для ПВВБП (0.47123992242919727).

5. Висновки.

Щодо дисперсій оцінок, та середніх цін для розміщень різних видів: пропорційного, Неймана та оптимального, суттєвої різниці немає, але в порівнянні з ПВВБП різниця в деяких випадках є досить суттєвою.

Щодо легкості підрахунків, то найлегшим є пропорційний відбір. Саме тому, певно, він і є найпопулярнішим серед всіх розміщень при стратифікованому відборі.

Якщо казати про вартість обстеження, то тут всі розміщення є приблизно однаковими по ціні, але в порівнянні з ПВВБП є вигіднішими.

Оскільки до вивчення цього курсу я була знайома тільки з пропорційним розміщенням, то для мене він є найзручнішим в обчисленнях та, в цілому, найлегшим. Дуже добре те, що він не програє в точності результатів (хоча б для цієї роботи) іншим видам розміщення при стратифікованому відборі.